Reconstrucción y regularización en imágenes tomográficas

Métodos Computacionales: TP

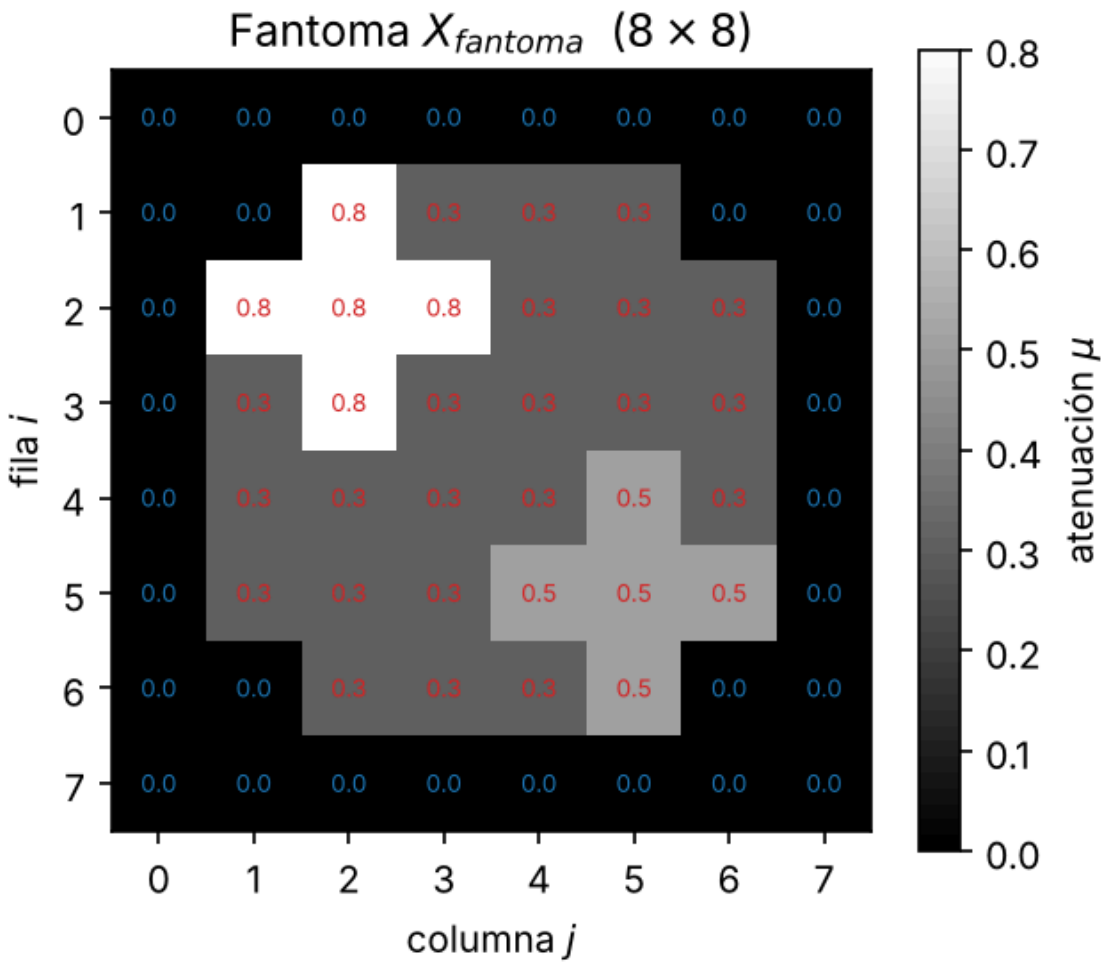
¿Cómo se recupera una imagen a partir de sus proyecciones?

- Modelo directo: $b = Ax$
- x: imagen vectorizada. b: mediciones de los rayos.
- Con ruido: $b_\sigma = b + \eta$. Se regulariza.

Ej. 1: ¿Una imagen es un vector?

- Fantoma 8×8 → vector de **64** componentes
- Pixel $(i, j) \leftrightarrow$ componente $k = i\,n + j$
- x_k = atenuación del píxel

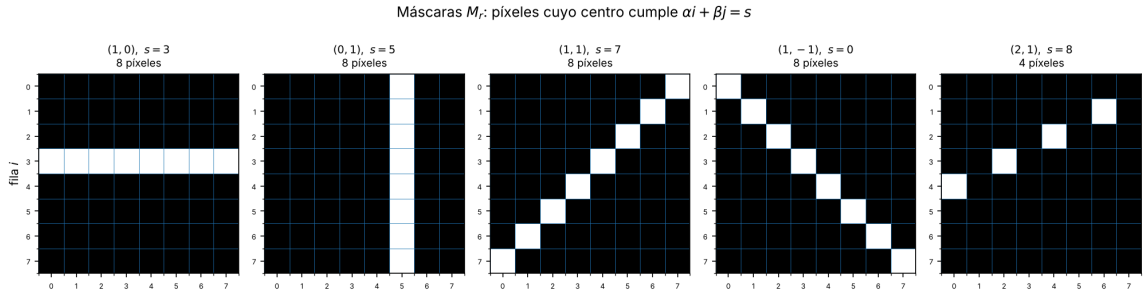
Mirar: valores por píxel; el negro es cero atenuación.



Ej. 2: ¿Qué es un rayo?

- Rayo (α, β, s): píxeles con $\alpha i + \beta j = s$
- Una medición es la **suma** bajo el rayo
- $(2, 1)$ toca solo 4 píxeles

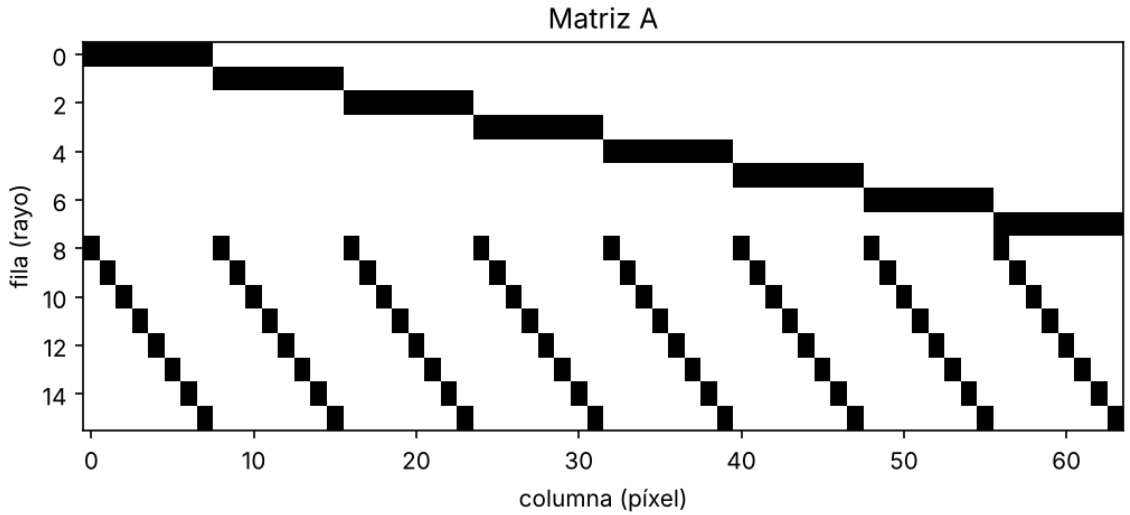
Mirar: fila, columna, diagonales y una recta inclinada.



Ej. 3: ¿Cómo es la matriz A?

- Fila = rayo; columna = píxel
- Con 2 direcciones: $A \in \mathrm{R}^{16\times 64}$
- Dispersa: **8** de 64 píxeles por rayo

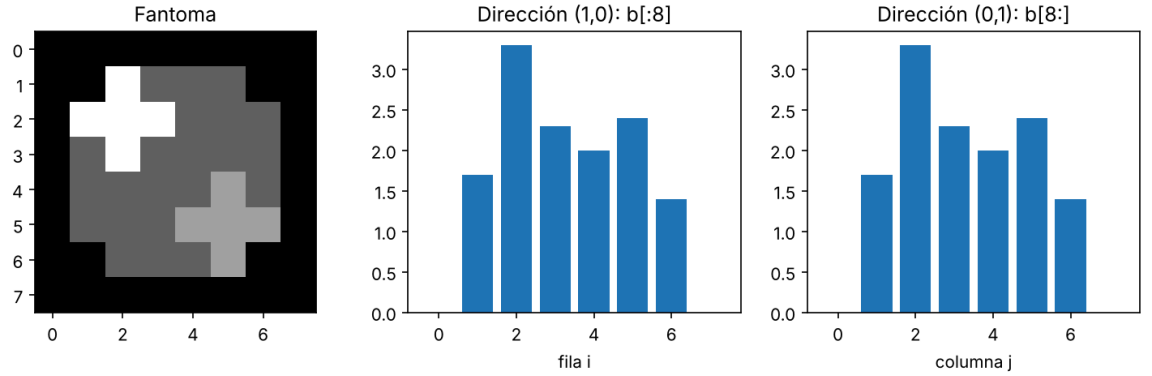
Mirar: pocos unos sobre muchos ceros.



Ej. 3: ¿Qué da $b = Ax$?

- $b[:8]$ = sumas por fila
- $b[8:]$ = sumas por columna
- $\sum b = 26{,}2 = 2 \cdot \sum x$

Mirar: las barras copian el perfil del fantoma.



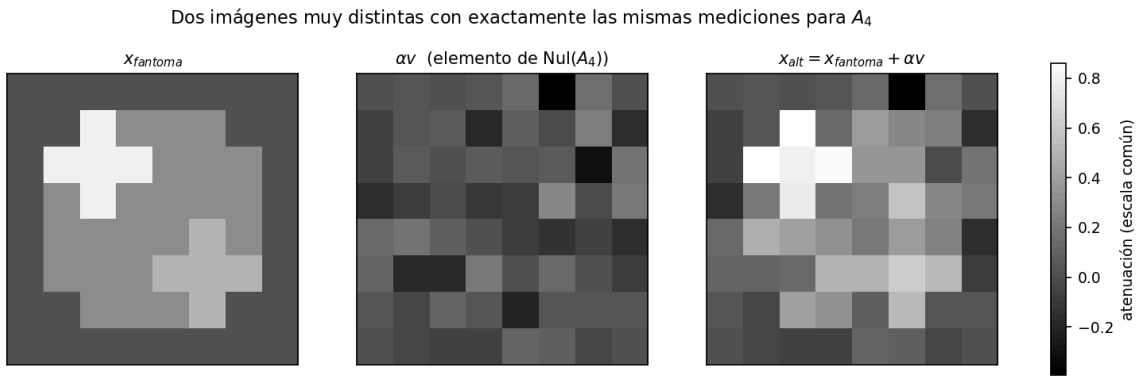
Ej. 4: ¿Alcanzan las mediciones?

Direcciones	Rango	dim Nul
2 (16×64)	15	49
4 (46×64)	39	25
7 (119×64)	**64**	0

Ej. 4: ¿Dos imágenes con las mismas mediciones?

- $v \in \mathrm{Nul}(A_4)$: suma 0 en toda recta
- $x_{alt} = x + \alpha v$ cambia la imagen
- Pero $A_4 x_{alt} = A_4 x$

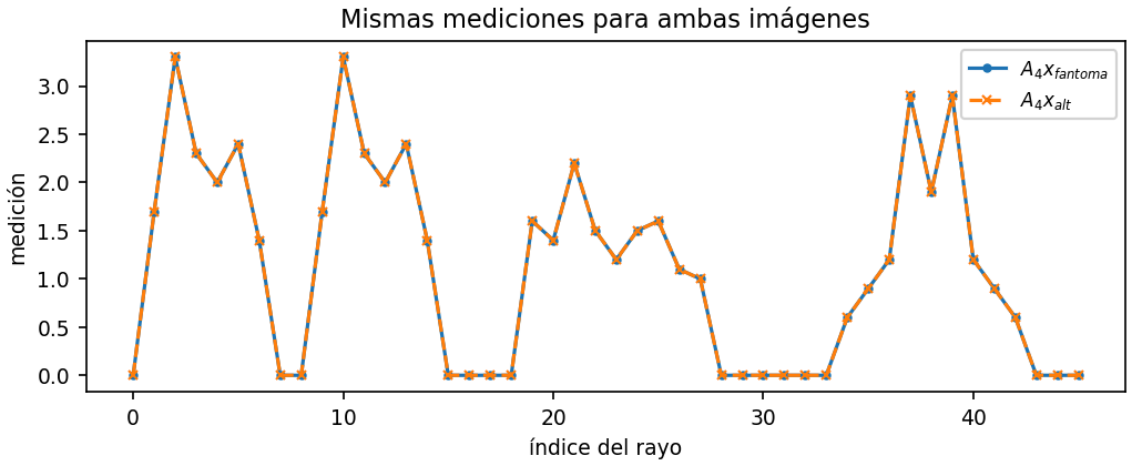
Mirar: fantoma, αv y la imagen alternativa.



Ej. 4: ¿Se distinguen las mediciones?

- $A_4x_{fantoma}$ y A_4x_{alt} se superponen
- Diferencia: **1,9e-15**
- Con A_4 no hay unicidad

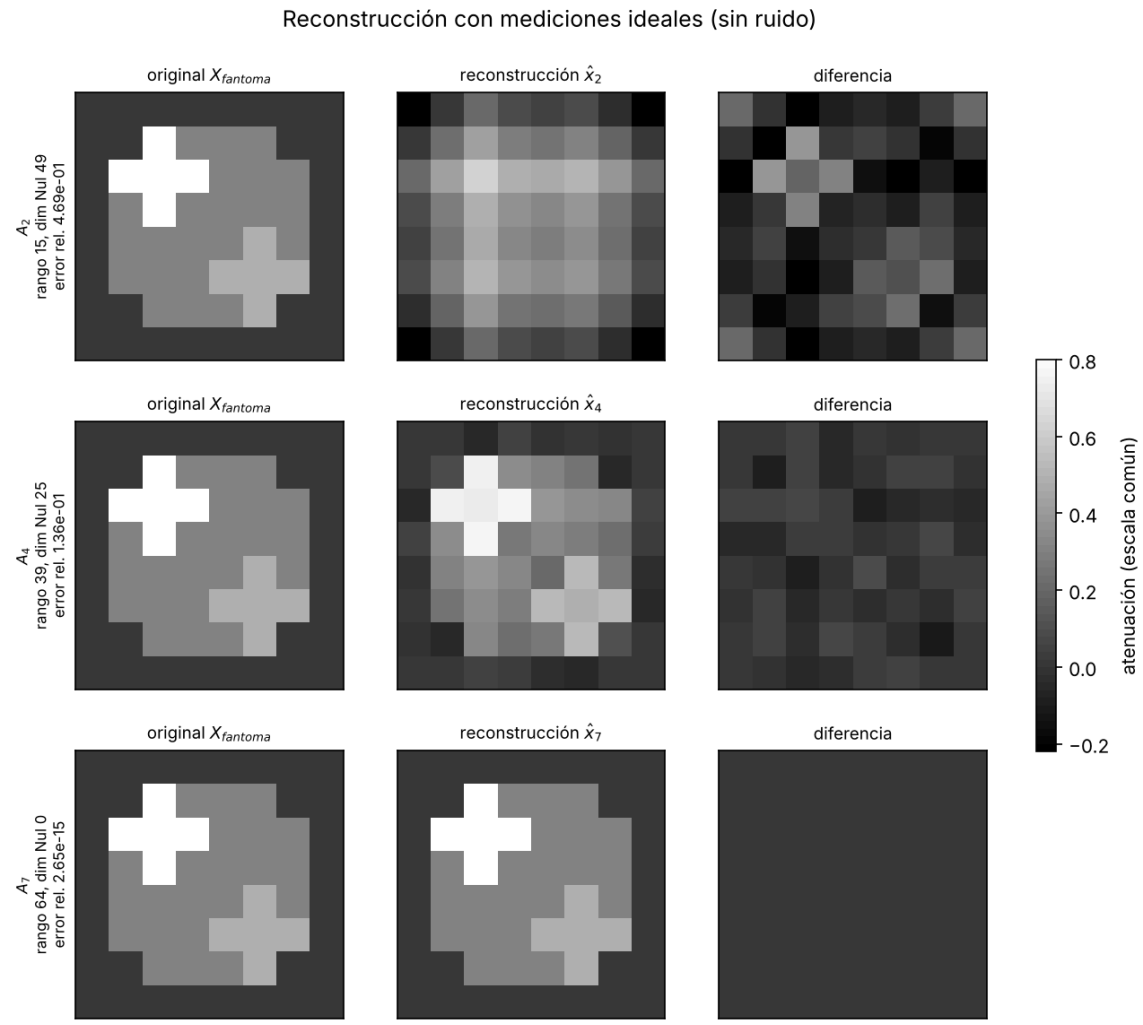
Mirar: las dos curvas son indistinguibles.



Ej. 5: ¿Se recupera la imagen sin ruido?

- Residuo ≈ 1e-14 en los tres casos
- Error: 0,469 (A2), 0,137 (A4)
- **2,1e-15** con A7

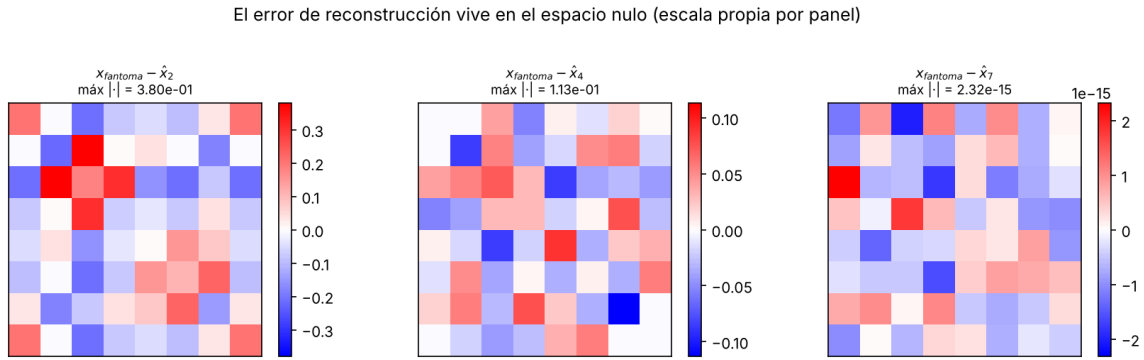
Mirar: filas original, reconstrucción y diferencia.



Ej. 5: ¿Basta un residuo chico?

- Residuo mide coherencia, no parecido
- El error vive en $\mathrm{Nul}(A)$
- Solo vale con rango completo

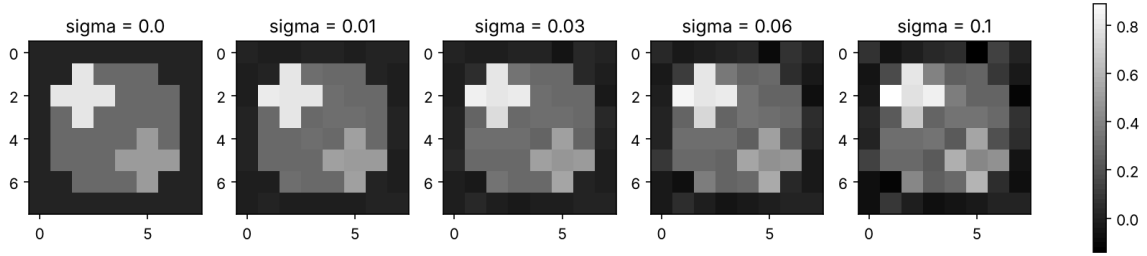
Mirar: la diferencia en A7 es ruido numérico.



Ej. 6: ¿Qué hace el ruido?

- $b_\sigma = b_7 + \sigma \,\text{escala}\, z$, semilla 912
- Error 0,021 → 0,210 para σ de 0,01 a 0,10
- Crece proporcional a σ

Mirar: más σ, más grano.



Ej. 6: ¿Por qué residuo no nulo y negativos?

σ	$\|\eta\|$	residuo	error
0,03	0,3977	0,2668	0,0630
0,06	0,7953	0,5336	0,1261
0,10	1,3256	0,8893	0,2102

- $b_\sigma \notin \mathrm{Col}(A_7)$; lstsq sin positividad

Ej. 7: ¿Qué propiedad tiene el residuo?

- $A_7^T r \approx 0$: $r \perp \text{Col}(A_7)$
- $A_7 \hat{x}$ = proyección ortogonal de b_σ
- $\|A_7^T r\| =$ **4,1e-14**

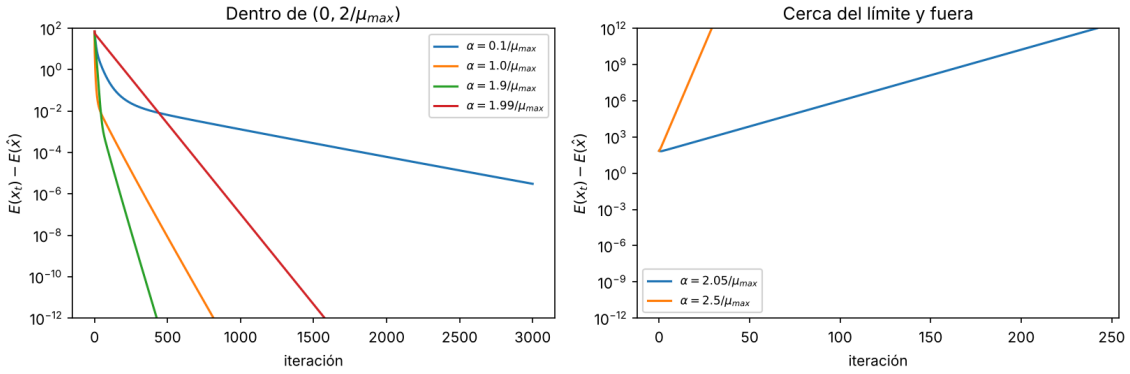
Ej. 8: ¿Cómo es el Hessiano?

- $E(x) = \frac{1}{2}\|Ax - b\|^2$, $H = A^T A$ definido positivo
- $\mu_{max} = 36{,}46$; $\mu_{min} = 0{,}51$
- $\text{cond}(H) \approx$ **71**

Ej. 8: ¿Qué tasa de aprendizaje sirve?

- Converge si $0 < \alpha < 2/\mu_{max}$
- $\alpha = 1/\mu_{max}$: **1169** iteraciones
- $2{,}05/\mu_{max}$ o más: diverge

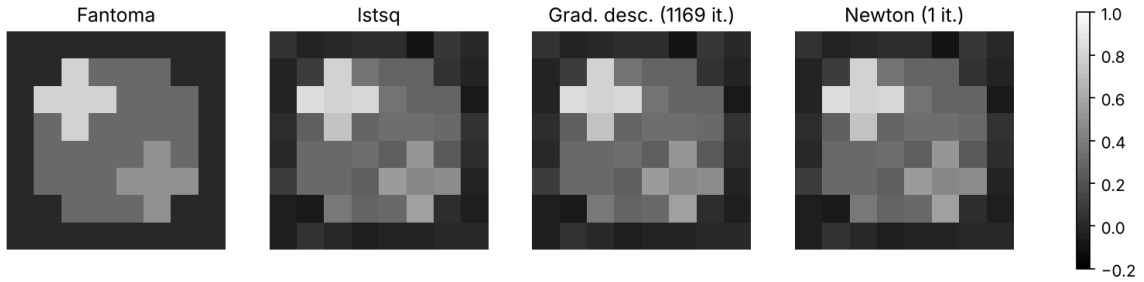
Mirar: azul lenta, verde rápida, derecha diverge.



Ej. 8: ¿Y Newton?

- E cuadrática → Newton en **1** paso
- Los tres métodos: mismo costo 0,142363
- Con 128×128, H sería 16384×16384

Mirar: lstsq, GD y Newton son iguales.



Ej. 9: ¿Qué es regularizar?

- $J = \frac{1}{2}(\|A_7 x - b\|^2 + \lambda \|Dx\|^2)$
- D resta píxeles vecinos (112×64)
- $\|Dx_{cte}\| = 0$; $\|Dx_{fantoma}\| =$ **2,71**

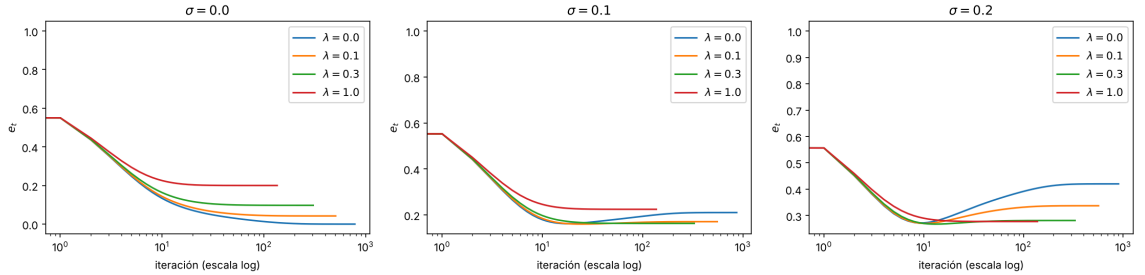
Ej. 9: ¿Qué lambda conviene?

σ	$\lambda = 0$	$\lambda = 0{,}3$	$\lambda = 1$
0,00	**0,0000**	0,0972	0,2000
0,10	0,2101	**0,1629**	0,2243
0,20	0,4203	0,2814	**0,2775**

Ej. 9: ¿Parar antes también regulariza?

- Con ruido, el error baja y luego sube
- Mínimo: iteración **18** (σ 0,10), **9** (σ 0,20)
- Sin ruido: baja hasta 0

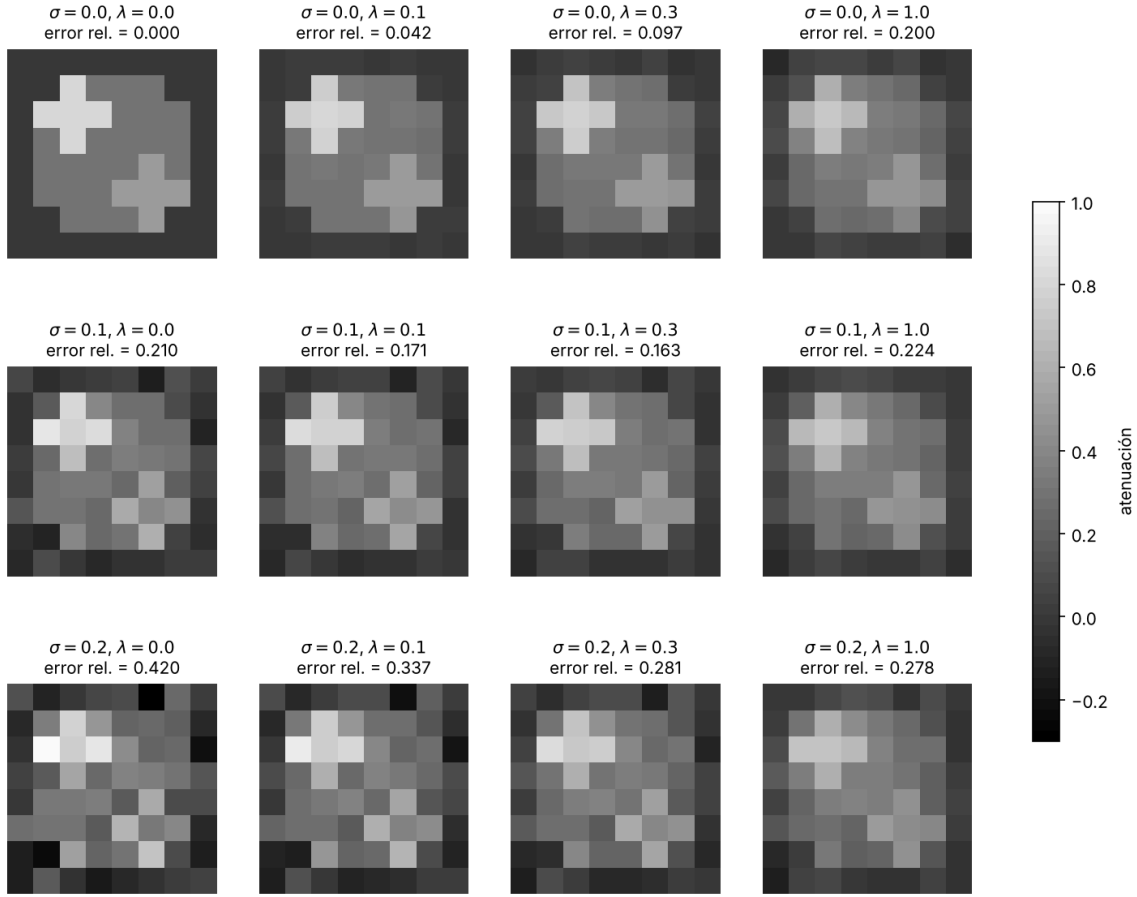
Mirar: azul ($\lambda = 0$) sube al final con ruido.



Ej. 9: ¿Cómo se ven las reconstrucciones?

- λ adecuado limpia el ruido
- λ grande aplana los picos
- Mejor λ sube con σ

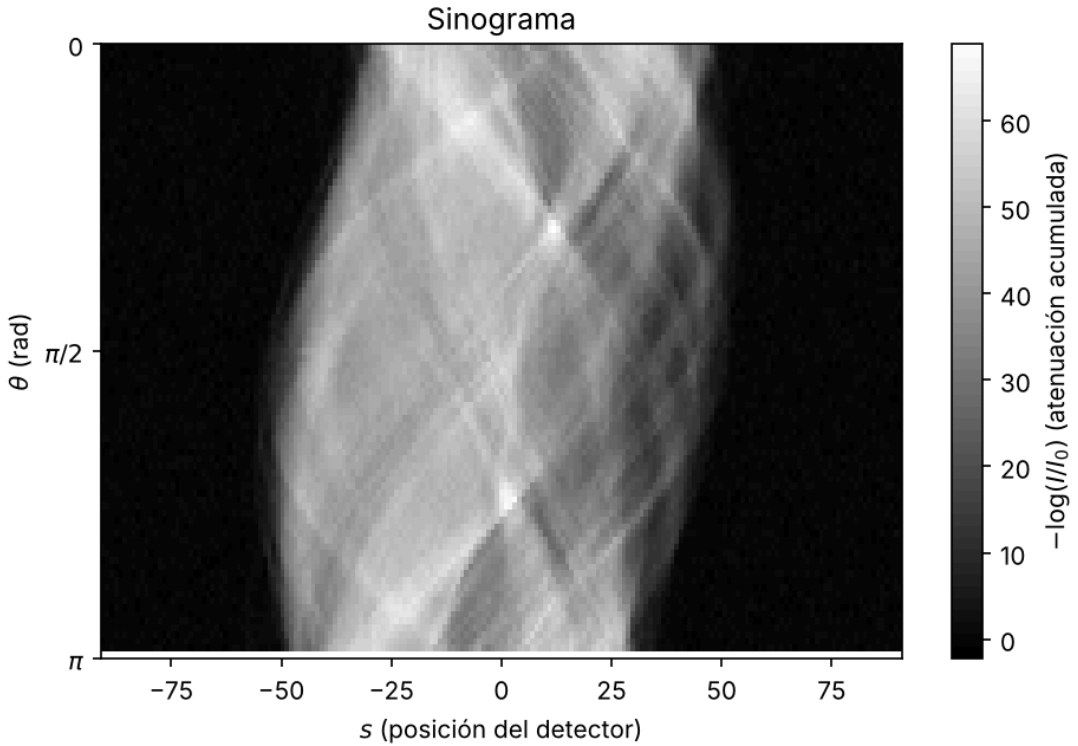
Mirar: nitidez contra grano según λ.



Ej. 10: ¿Datos reales?

- $n = 128$, 90 ángulos, 183 detectores
- A: 16470×16384, **0,70%** no nulos
- Se usa GD con $\alpha = 1/L$

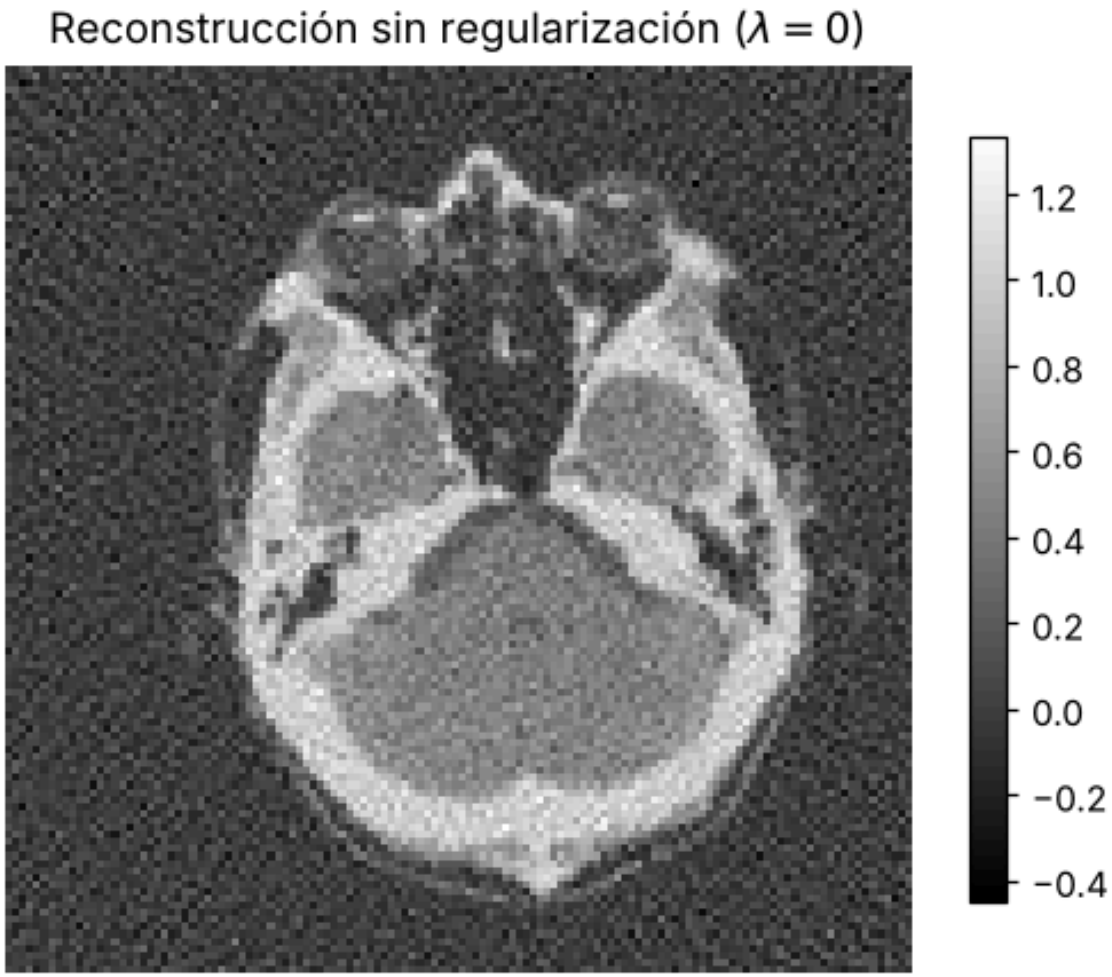
Mirar: eje s (detector) contra ángulo θ.



Ej. 10: ¿Qué pasa sin regularizar?

- $\lambda = 0$: residuo **41,23**
- $\|\eta\| \approx 75{,}97$: se ajusta el ruido
- Mínimo de la imagen: −0,448

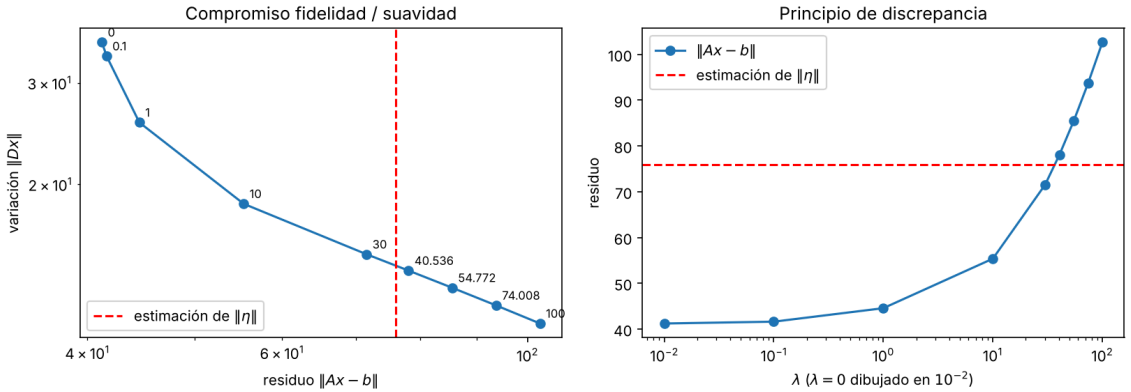
Mirar: grano en el fondo y bordes.



Ej. 10: ¿Cómo se elige λ?

- Principio de discrepancia: residuo $\approx \|\eta\|$
- $\lambda = \mathbf{40{,}536}$: residuo 78,07
- Razón con $\|\eta\|$: 1,03

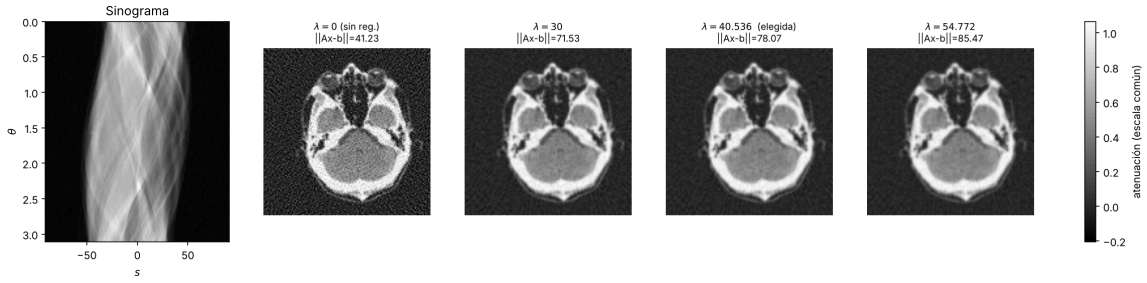
Mirar: la curva cruza la línea roja entre 30 y 100.



Ej. 10: ¿Cómo queda la reconstrucción?

- $\|Dx\|$: 35,27 → **14,17**
- Mínimo: −0,448 → −0,094
- Se conserva la anatomía

Mirar: sinograma, $\lambda = 0$ y vecinos de la elegida.



Ej. 11: ¿Qué aprendimos?

- Problema inverso mal planteado (Hadamard)
- Rango 15 / 39 / 64 → Nul 49 / 25 / 0
- Con ruido: $\|\eta\| = 0{,}795$ vs $\|r\| = 0{,}534$

Conclusión: un solo hilo

Modelo directo → unicidad → ruido y mínimos cuadrados → métodos iterativos → regularización → datos reales

- $b = Ax$ solo se invierte si rango$(A) = 64$
- Con ruido, regularizar y elegir λ con la discrepancia